

基于多源数据的汽车召回主题演变与预警机制研究

方珺逸 向苡萱 王彪

中南大学商学院

摘要

在全球汽车产业快速发展的背景下，汽车召回问题日益凸显，对汽车制造商、消费者及监管部门均构成了严峻挑战。为有效应对汽车召回风险，本研究基于多源缺陷信息，建立了一种汽车召回预警模型。该模型运用 LDA-MLC 模型结合 n -gram 技术，对多元文本数据进行了时序变点建模和主题漂移分析。实验中，通过具有市场代表性的车企召回公告和投诉评论案例验证了模型的有效性和适用性。本研究为汽车制造商提供了前瞻性的风险提示，有助于其及时调整生产策略、改进产品质量，降低召回风险；同时，对于提升汽车行业的质量安全管理水平具有重要意义。

关键词： 汽车召回、多源缺陷信息、LDA-MLC、 n -gram 模型、主题漂移、文本挖掘

1 引言

1.1 研究背景

在全球汽车行业快速拓展的背景环境下，汽车质量问题已成为行业可持续发展的关键要素，引起了汽车企业、学术界、监管部门的普遍重视，伴随汽车技术持续进步和汽车保有量不断攀升，召回事件产生的频率也在不断上升，这些召回事件不仅让汽车企业承受高昂召回成本压力，还使品牌形象受损^[1-3]。以丰田汽车“踏板门”事件做例子，企业不仅耗费了巨额资金进行召回与维修，品牌声誉同样遭到严重破坏，市场份额大幅下降^[4]。该事件充分体现了汽车召回问题的重要意义，也表明打造精准有效的汽车召回预警模型、借助多源缺陷信息提前识别可能的召回风险，已成为汽车行业亟待攻克的重要问题。

目前已有针对汽车召回的相关研究，多把焦点放在产品召回对企业的影响上，学者们采用多种途径开展探究，就像观察股票市场价格，来研究召回事件给企业异常收益带来的

影响^[5-9]；关注以往召回对未来召回成效的影响^[10-12]；分析市场份额的变化趋势^[1]、未来可能出现的意外事故^[13]以及召回成本^[14-15]等。这些研究大多把发达国家的汽车市场作为研究的目标对象，对发展中国家的新兴市场关注尚显不足。

新兴经济体的汽车市场迅速崛起壮大，在 2009 年中国变为全球最大的汽车市场^[3]。在处于成熟阶段的汽车市场，宛如美国^[1,11]、英国^[16]和日本^[17]，企业、监管机构、投资者和消费者均接受汽车召回这种常态。与之构成鲜明反差的是，新兴市场有关汽车召回的相关研究相对偏少，就中国而言，尽管中国汽车市场呈现出庞大的规模，但在召回情况上和美国等成熟市场比起来还是存在差距^[3]。此现状体现出新兴市场的汽车行业有巨大发展空间，同时也为相关研究带来了新的指引。

从 2024 年全球汽车品牌 TOP20 销量排名所呈现的国家分布¹我们能知道，日本、德国、美国和韩国的汽车品牌在全球市场销量方面占据关键地位，说明全球汽车市场的引领者是这些发达国家，中国的吉利和五菱汽车同样跻身全球销量前 20，说明新兴市场在汽车产业中也有极大潜力。




图 1: 2024 年全球汽车品牌销量排名 (Top20) 国家分布

¹数据来源：<https://baa.yiche.com/qichezatan/thread-52086300.html>

伴随新兴市场不断推进发展，我们看到在国际市场，更多的中国品牌与其他新兴市场品牌日益活跃，呈现出改变全球汽车市场格局的势头，未来汽车召回研究要进一步关注这些新兴市场的动态及发展，从而更好地贴合全球汽车行业的发展趋向。

从研究方法这个维度，现有研究采用了实证建模^[1,11]、事件研究^[5-6,8-9]、比较分析^[10-11,16]等多种方法来分析召回相关问题。Shi 等^[3]将中国和美国的汽车召回情况进行对比，提出了一个包含国家、发起者以及企业层面的比较框架体系，研究知悉中国市场的召回绩效比美国市场差，而且诸如所有权结构等因素会影响召回绩效，这些研究方法跟成果为后续的研究奠定了基础，但同样存在着一定的局限。

汽车召回预警模型研究面对诸多挑战，传统预警途径依赖单一的信息源，很难全面抓住汽车缺陷的复杂特征和潜在风险^[18-19]。伴随汽车生产等过程出现大量多源异构数据，数据整合利用变得越发棘手，当前的数据处理技术存在数据融合障碍、特征提取不精准等问题^[19-20]。这造成传统预警模型在准确性和及时性上无法满足实际需要，难以有效处理日趋复杂的汽车召回问题。

随着大数据时代的到来，多源数据为深入剖析汽车召回问题给出了新契机，采用收集和分析汽车行业投诉与召回信息平台的数据，可更全面地获悉汽车产品质量问题的时空分布特点，本研究作出的贡献是采用数据驱动的研究手段，运用 n -gram 改进的 LDA-MLC 模型对汽车召回前后的投诉数据进行研究，目标是观察企业发出召回公告后投诉主题浓度出现的变化，再去构建一个汽车召回预警模型。该模型为汽车制造企业提供预报性的风险监控，协助其及时更改生产策略、优化产品质量，减少汽车召回的几率；为监管机构提供更充足的监管凭据，协助制订更科学合理的方针，加强对汽车行业整体质量的把控；为消费者提供更为可靠的购车指引，增进消费者对汽车市场的信心感。

1.2 研究目标与框架

本研究计划通过分析 2024 年汽车品牌全球销量位列前 20 的车企某些车型的投诉及召回数据，构建由多源缺陷信息驱动的汽车召回预警模型，以下为具体研究目标：

1. **建立汽车召回预警模型**：基于整合后的多源数据，运用数据驱动的方法，即 LDA-MLC 模型结合 n -gram 技术，开发能够精准预测汽车召回风险的预警模型。
2. **构建多源数据整合框架**：整合来自不同汽车行业投诉与召回信息平台的多源异构数据，包括消费者投诉、召回公告等，形成全面的数据集，为模型构建提供数据支撑。

3. **验证模型有效性与适用性**：通过案例分析，特别是针对 2024 年汽车品牌全球销量 TOP20 中的重点品牌，验证所开发预警模型的有效性和适用性。

为实现上述目标，本研究将按照以下框架展开：

1. **文献综述**：系统梳理国内外关于汽车召回的相关研究，分析现有研究的不足与空白，为本研究提供理论基础和方法借鉴。重点探讨汽车召回的分析方法演进、政策与市场趋势对召回的影响、技术工具与模型迭代，以及现有研究体系的不足之处。
2. **方法论**：详细介绍本研究采用的建模方法，包括基于 LDA 的时间序列变点主题模型，以及 n-gram 技术在细粒度文本语义捕捉中的应用。阐述如何通过这些方法实现投诉话题浓度分析，为汽车召回预警提供技术支撑。
3. **实验与分析**：首先进行多源数据的采集与清洗，确保数据的准确性和可用性。经过市场可信度检验后，选取案例，分析验证模型的有效性和适用性，并得出有价值的启示。
4. **结论**：总结本研究的主要发现，强调其理论与实践意义。提出未来研究的改进方向，包括技术深化、应用拓展和政策协同等方面，为后续研究提供参考。

2 文献综述

汽车召回事件作为产品质量管理的重要环节，不仅关乎消费者权益保护，更直接影响企业声誉与市场竞争力。随着传感器技术、社交媒体及数据科学的快速发展，汽车召回数据分析已从单一事件记录转向多源异构数据驱动的预测性决策体系。

2.1 产品召回分析方法演进

社交媒体变为消费者表达产品体验的关键渠道，其内容分析为召回数据分析贡献了新维度。Zhong 和 Schweidel (2020)^[21]通过捕捉社交媒体对话中的变点，分析主题流行度变化，揭示了消费者关注点的动态迁移。Gao 等 (2022)^[22]的研究进一步证实，社交媒体上的不良药物反应讨论显著加速了药品召回过程，提示其在汽车召回中的潜在加速效应。结合 Fossen 和 Schweidel (2019)^[23]的产品植入效果评估方法，可量化社交媒体讨论对召回事件的影响强度，形成消费者行为分析的数字镜像。

时间序列分析是召回数据分析的基石。Chamroukhi 等 (2013)^[24]拟定的隐藏逻辑过程回归模型，依靠多项式回归和逻辑函数生成信号，可有效获取铁路开关信号中的非线性特征，该方法在汽车召回数据分析时可运用到传感器信号去噪与故障特征提取，为预测性维

护给予数据支撑。Chib (1998)^[25]的多变点模型采用隐离散状态变量和 MCMC 方法，抬高了时间序列分段估计的效率，适合探测召回数据里故障模式的改变点，两者共同构建起时间序列特征提取的方法论体系，为召回数据分析给出了微观方面的视角，也为我们正在研究的模型构建部分带来了启示意义。

消费者行为研究揭示了在线投诉、媒体报道等因素对召回及销量的影响机制。Wang 等 (2023) 的研究发现在线评论数据可以提供消费者对产品质量的直接反馈^[26]，利于企业知晓产品瑕疵和市场反响，从而及时运用召回等补救方式，通过剖析在线评论的走向和样式，企业有能力预测潜在的市场需求及风险，为产品召回决策提供佐证。各类企业都应积极管理线上评论，尤其是那些负面的评论，对于维护品牌形象和消费者信任意义重大，企业应及时对消费者的反馈做出反应，采取有效行动解决产品故障，这一结论提示企业得重点关注那些高集中度、高负向情绪的投诉，以此优化召回策略。Astvansh 等 (2022)^[27]的研究则表明，新闻媒体报道量显著增加企业自愿召回数量，负面报道尤其关键，而媒体评级则削弱了这种影响。这为召回策略制定提供了外部压力与声誉缓冲的双向调节框架。

2.2 政策、市场趋势与财务影响

汽车产业政策对市场趋势以及召回事件影响重大。Chen 等 (2024)^[28]分析了中国汽车产业政策的演变阶段，指出政策在推动产业不断快速发展中的关键意义。Bates 等 (2007)^[16]对英国汽车召回趋势进行的分析发现，召回事件数量的增加与汽车制造商面临的更严峻质量控制挑战紧密相连，政策因素借助改变市场准入条件、质量监管程度及消费者预期，间接影响召回数据分析所得结论的有效性，就像新能源汽车产业政策会对召回事件的原因分布造成改变，研究者应按实际情况调整分析模型。

召回事件不仅损害品牌形象，还带来显著的财务影响。Zhao 等 (2013)^[9]研究表明，产品召回公告在中国市场显现出显著的负面财务影响，况且主动召回公告披露后，股价的反应相对平稳，这启示企业得强化产品质量的把控，降低产品召回几率。

当前研究已呈现多学科交叉趋势。McKinsey (2023) 的消费者洞察报告²揭示，电动汽车市场崛起、全渠道运营重要性凸显等趋势，为召回数据分析提供了新的研究场景。Wang 等 (2023)^[26]所进行的在线评论与汽车销量关系研究，就采用了计量经济学和消费者行为理论相结合的方式，发现评论效价跟销量呈现倒 U 型的关系，评论数量对销量起到积极的促进效果，这一主题建模同经济学分析的融汇，为召回数据的分析打造了更精细的消费者行为描述工具。

²McKinsey China Auto Consumer Insights 2023, July 14, 2023

2.3 技术工具与模型迭代

召回数据分析的技术工具不断创新。Grootendorst (2022)^[29]提出的 BERTopic 模型, 利用预训练语言模型生成文档嵌入, 并通过基于类别的 TF-IDF 程序生成主题表示, 显著提升了主题建模的准确性和解释性。在汽车召回数据分析中, BERTopic 可用于从消费者反馈、媒体报道等文本数据中提取关键主题, 跟踪召回事件相关主题的动态变化。结合 Chib (1996)^[30]的马尔可夫混合模型 (MMM), 可进一步识别召回事件对汽车性能、消费者反馈的影响状态, 实现多源数据的动态集成分析。

2.4 研究体系与现有空白

现有文献已搭建起一个涵盖“数据驱动-行为洞察-政策反馈”的闭环研究体系, 在这一整套体系里, 数据驱动层采用时间序列分析与社交媒体挖掘的方法, 为召回数据分析提供了可靠的基础数据支撑; 行为洞察层借助开展消费者行为研究以及主题建模手段, 深度挖掘了召回事件背后的微观机理; 政策反馈层经由产业政策分析与财务影响评估, 给召回事件研究设置了宏观层面约束。

然而, 尽管研究体系已相对完善, 但仍存在一些亟待填补的研究空白。首先, 如何有效整合传感器数据、社交媒体数据、政策文本等多源异构数据, 以构建全面的召回数据分析框架, 是当前研究面临的一大挑战。其次, 开发基于统计学习、机器学习和大数据技术的实时舆情数据流监测系统, 及时发现并预警潜在召回事件, 也是未来研究的重要方向。此外, 跨文化比较研究以及政策效果评估模型的建立, 对于深入理解不同国家、地区汽车召回制度的差异及其对市场反应的影响, 以及量化产业政策对召回事件和市场趋势的具体作用, 同样具有重要意义。

3 方法论

3.1 基于 LDA 的时间序列变点主题模型

潜在狄利克雷分配 (Latent Dirichlet Allocation, LDA) 是主题建模领域的经典概率生成模型, 广泛应用于自然语言处理、信息检索等领域。其核心假设为: 文档由多个潜在主题混合生成, 单词基于主题分布产生。

在 LDA 模型框架中, 设文档集合包含 D 篇文档, 主题数量为 J , 词汇表大小为 W 。

对于第 d 篇文档，LDA 的文档集联合分布为：

$$P(W, Z, \Theta, \Phi | \alpha, \beta) = P(\Theta | \alpha) P(\Phi | \beta) \prod_{d=1}^D P(Z^{(d)} | \theta^{(d)}) P(W^{(d)} | Z^{(d)}, \Phi) \quad (1)$$

其中， W 为所有文档的词集合， Z 为词的主题编号集合， Θ 为文档主题分布集合， Φ 为主题词分布集合。 $P(\Theta | \alpha)$ 和 $P(\Phi | \beta)$ 分别表示文档主题分布和主题词分布的先验； $\prod_{d=1}^D P(Z^{(d)} | \theta^{(d)})$ 是给定文档主题分布生成词主题编号的概率， $\prod_{d=1}^D P(W^{(d)} | Z^{(d)}, \Phi)$ 是基于词主题编号和主题词分布生成文档词集合的概率。

其中， W 为所有文档的词集合， Z 为词的主题编号集合， Θ 为文档主题分布集合， Φ 为主题词分布集合。 $P(\Theta | \alpha)$ 和 $P(\Phi | \beta)$ 分别表示文档主题分布和主题词分布的先验； $\prod_{d=1}^D P(Z^{(d)} | \theta^{(d)})$ 是给定文档主题分布生成词主题编号的概率， $\prod_{d=1}^D P(W^{(d)} | Z^{(d)}, \Phi)$ 是基于词主题编号和主题词分布生成文档词集合的概率。基于吉布斯采样的结果，可得到后验分布的参数估计：

$$\hat{\phi}_j^{(w)} = \frac{n_j^{(w)} + \beta}{n_j^{(\cdot)} + W\beta} \quad (2)$$

$$\hat{\theta}_j^{(d)} = \frac{n_j^{(d)} + \alpha}{n^{(d)} + J\alpha} \quad (3)$$

其中， $\hat{\phi}_j^{(w)}$ 表示主题 j 中单词 w 的概率， $\hat{\theta}_j^{(d)}$ 表示文档 d 中主题 j 的概率，分别通过主题 - 词计数 $n_j^{(w)}$ 、文档 - 主题计数 $n_j^{(d)}$ 及超参数 α, β 计算得到，用于刻画主题内词分布和文档主题分布。

3.1.1 LDA-MLC 模型

狄利克雷过程隐马尔可夫模型 (DP-HMM) 被引入以改进传统 LDA 模型，构建 LDA-MLC 模型。在该模型中，假设存在多个潜在状态，由狄利克雷参数向量 $\alpha_0 m^{(k)}$ 表示文档的话题流行度，从这些状态中抽取，且在观察时间窗口内固定每个话题的词分布。

1. 模型生成过程

- (a) 选择一个状态 $k \sim P(s_t | s_{t-1})$ ，其中 s_t 是时间 t 的离散状态， $t = 1, 2, \dots, T$ ，在时间 t 贡献的文档属于状态 k 。
- (b) 对于状态 k 中的每个文档 d （记状态 k 下的文档集合为 $\mathcal{C}_k$ ， $k \in \mathbb{Z}^+$ ， $k \leq T$ ），从狄利克雷分布中选择主题分布：

$$\theta^{(d)} \sim \text{Dirichlet}(\alpha_0 m^{(k)}) \quad (4)$$

(c) 对于文档 d 中的每个词 i :

i. 选择一个主题

$$z_i \sim \text{Multinomial}(\theta^{(d)}) \quad (5)$$

ii. 选择一个单词

$$w_i|z_i \sim \text{Multinomial}(\phi^{(z_i)}) \quad (6)$$

其中, $\phi^{(z)} \sim \text{Dirichlet}(\beta)$ 。

2. DP - HMM 转移矩阵与转移概率: 使用 DP - HMM 实现状态转移, 其转移矩阵 P 形式为:

$$P = \begin{bmatrix} p_{11} & p_{12} & 0 & \cdots \\ 0 & p_{22} & p_{23} & \cdots \\ \vdots & \vdots & \ddots & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix} \quad (7)$$

从状态 k 出发, 仅允许保持在状态 k 或转移到下一个状态 $k+1$, 即 $p_{kk} + p_{k,k+1} =$

1。在 DP-HMM 的狄利克雷过程先验下, 转移概率由下式给出:

$$p(s_t = k | s_{t-1} = j) = \begin{cases} \frac{n_{jj} + v}{n_{jj} + v + \lambda} & k = j \\ \frac{\lambda}{n_{jj} + v + \lambda} & s_t \text{ 进入新状态} \end{cases} \quad (8)$$

其中, n_{jj} 表示从状态 k 到自身的转移计数, λ 是控制保持当前状态倾向的超先验, v 是控制转移到下一个状态倾向的超先验。

3. 联合分布: 词 w 和主题分配 z 的联合分布为:

$$P(w, z | \alpha_0 m, \beta, s) = P(w | z, \beta) \prod_{t=1}^T \prod_{d \in \mathcal{C}_t} P(z^{(d)} | \alpha_0 m^{(s_t)}) \quad (9)$$

其中, s 表示每个时间 t 的状态序列 S_t , $z^{(d)}$ 表示文档 d 中词的主题分配, $\mathcal{C}_t$ 表示时间 t 的文档集合。

4. LDA - MLC 混合算法

(a) $z|w, m, s$: 对于任何文档 $d \in \mathcal{C}_t$ (其中状态 $s_t = k$), 标记 i 被分配到主题 j 的条件分布为:

$$\begin{aligned} P(z_i = j | z_{-i}, w) &\propto \frac{P(z_i = j, z_{-i}, w | \alpha_0 m^{(k)}, \beta)}{P(z_{-i}, w_{-i} | \alpha_0 m^{(k)}, \beta)} \\ &= \frac{n_{-i,j}^{(w_i)} + \beta}{n_{-i,j}^{(\cdot)} + W\beta} \left(n_{-i,j}^{(d_i)} + \alpha_0 m_j^{(k)} \right) \end{aligned} \quad (10)$$

文档主题分布 θ 的估计为:

$$\hat{\theta}_j^{(d)} = \frac{n_j^{(d)} + \alpha_0 m_j^{(k)}}{n^{(d)} + \alpha_0} \text{ if } d \in \mathcal{C}_k \quad (11)$$

(b) $m|z, s$: 由于 $\alpha_0 m^{(k)}$ 涉及到 $p(w|z, \beta)$ 和 $p(\beta)$, 概率测度 m 可在给定其他参数时单独采样。根据 LDA 生成过程, 每个文档的主题比例 θ 从参数为 α 的狄利克雷分布中抽取, 这种复合分布是狄利克雷 - 多项分布。因此, $\alpha_0 m$ 在给定主题分配 z 和状态 s 下的似然为:

$$L(\alpha_0 m | z, s) = P(z | \alpha_0 m, s) = \prod_{t=1}^T \prod_{d \in \mathcal{C}_t} \left(\frac{\Gamma(\alpha_0)}{\Gamma(n^{(d)} + \alpha_0)} \prod_{j=1}^J \frac{\Gamma(n_j^{(d)} + \alpha_0 m_j^{(s_t)})}{\Gamma(\alpha_0 m_j^{(s_t)})} \right) \quad (12)$$

其中, $n_j^{(d)}$ 计算文档 d 中分配到主题 j 的标记数量, $n^{(d)}$ 计算文档 d 中所有标记的总数。考虑到迭代过程中状态 k 的变化数量以及每个状态 k 下 $m^{(k)}$ 的条件独立性, 每 20 次迭代使用定点迭代最大化上述似然来估计概率测度 m 。

(c) $s|m, z$: 假设状态转移遵循隐藏马尔可夫链, 状态数量内生确定。状态 s 在给定主题分配 z 和概率测度 m 下的似然为:

$$\begin{aligned} L(s | \alpha_0 m, z) &= p(z | s, \alpha_0 m) = \prod_{t=1}^T \prod_{d \in \mathcal{C}_t} p(z^{(d)} | \alpha_0 m^{(s_t)}) \\ &= \prod_{t=1}^T \prod_{d \in \mathcal{C}_t} \left(\frac{\Gamma(\alpha_0)}{\Gamma(n^{(d)} + \alpha_0)} \prod_{j=1}^J \frac{\Gamma(n_j^{(d)} + \alpha_0 m_j^{(s_t)})}{\Gamma(\alpha_0 m_j^{(s_t)})} \right) \end{aligned} \quad (13)$$

s_t 可通过吉布斯采样依次抽取, $t = 1, 2, \dots, T$, 公式为:

$$p(s_t | S_{t-1}, S^{t+1}, \alpha_0 m, z) \propto p(s_t | s_{t-1}, S_{t-2}) p(s_{t+1} | s_t, S^{t+2}) \prod_{d \in \mathcal{C}_t} p(z^{(d)} | \alpha_0 m^{(s_t)}) \quad (14)$$

其中, $S_{t-2} = (s_1, s_2, \dots, s_{t-2})$, $S^{t+2} = (s_{t+2}, s_{t+2}, \dots, s_T)$ 。该方法要求当且仅当 $s_{t-1} \neq s_{t+1}$ 时对状态 s_t 进行采样。

3.1.2 细粒度文本语义捕捉： n -gram

在原始的 LDA - MLC 模型^[21]中，词袋模型以单个词为基本单元。为了捕捉文本中更丰富的语义信息，我们将词袋模型扩展到 n -gram，即使用 1 - n 个连续词组成的序列作为基本单元。传统的基于 LDA 的模型忽略了词袋假设下的单词排序和语义关系。放宽这种假设的一种方法是将我们的模型扩展到 n 元语法模型。在本文中，我们采用 n -gram 模型而非传统的 Bag-of-Words 模型来表示文本数据，原因如下：首先，Zhong 和 Schweddel 在 Marketing Science 上发表的论文^[21]指出 LDA-MLC 模型的词袋假设可能忽略语义关系，而 n -gram 模型能够更好地反映文本的局部结构，更加适用于动态话题建模任务；其次，汽车投诉评论中常出现复合术语， n -gram 模型在捕捉关键短语方面具有更高的准确性和表达能力；此外， n -gram 模型能够保留词语之间的顺序和上下文联系，而词袋模型则忽略了这些信息，例如“刹车失灵”和“失灵刹车”在词袋模型中被视为相同特征，但 n -gram 能体现出二者的语义差异，从而更准确地支持变点检测任务。

为全面捕捉文本特征，在特征提取中我们同时使用了 1-gram、2-gram 和 3-gram，使模型能够在不同粒度上提取主题相关的信息，从而更精准地支持后续的变点检测与话题分析任务。在 LDA-MLC 建模的进一步改进中， n -gram 的引入主要影响吉布斯采样中主题分配 z 和状态序列 s 的条件分布计算。

传统吉布斯采样公式(10)扩展到 n -gram 后，分子分母中的单词计数 $n_{-i,j}^{(w_i)}$ 和词汇表大小 W 需替换为 n -gram 单元的计数 $n_{-i,j}^{(\text{ngram})}(w_i)$ 和 n -gram 词汇表大小 W_{ngram} ，即：

$$P(z_i = j | z_{-i}, w) \propto \frac{n_{-i,j}^{(\text{ngram})}(w_i) + \beta}{n_{-i,j}^{(\cdot)} + W_{\text{ngram}}\beta} \left(n_{-i,j}^{(d_i)} + \alpha_0 m_j^{(k)} \right) \quad (15)$$

其中 $n_{-i,j}^{(\text{ngram})}(w_i)$ 表示排除当前 n -gram 单元 i 后，主题 j 中该 n -gram 单元的出现次数，体现 n -gram 单元的共现关系对主题分配的影响。

状态转移概率的计算仍遵循 DP-HMM 的前向转移假设（仅允许保持状态或转移至下一状态），但状态 s_t 对应的似然项 $\prod_{d \in C_t} P(z^{(d)} | \alpha_0 m^{(s_t)})$ 需基于 n -gram 单元的主题分配 $z^{(d)}$ 进行计算。具体而言， n -gram 的语义信息通过主题词分布 $\phi_{\text{ngram}}^{(z)}$ 影响文档主题分布 $\theta^{(d)}$ ，进而改变状态 s_t 的后验概率，使得状态转移决策更依赖于 n -gram 单元的语义聚类特征。

3.2 投诉话题浓度分析

在采用改进后的 LDA - MLC 模型成功检测出若干时间变点后,为进一步研究变点前后文本内容的潜在语义差异,本研究引入 LDA 主题模型来对文本数据进行进一步主题聚类分析, LDA 可看作无监督的概率生成模型,大量应用于自然语言处理领域里的主题建模任务。这个模型推断文本集合由多个“话题”组合起来的,每个话题则是由一组词汇按照一定的概率分布产生, LDA 对文本、话题、词汇这三层结构做建模,可从海量非结构化文本里自动提取出具备潜在语义一致性的话题,进而达成对文本集合潜在结构的剖析。

$$K^* = \arg \min_{k \in [5,25]} [\alpha \cdot \text{Perplexity}(k) + (1 - \alpha) \cdot (1 - \text{Coherence}(k))] \quad (16)$$

其中:

- 权重系数,经网格搜索确定
- 困惑度计算: $\text{Perplexity}(k) = \exp \left(-\frac{\sum \log p(w|d)}{N} \right)$
- 一致性得分: $\text{Coherence}(k) = \frac{1}{k} \sum_{t=1}^k \text{UCI}(t)$

在本项研究中,我们把识别出的每个变点当作时间分界点,根据变点前后,把汽车投诉评论数据分成多个阶段的子集,并分别就这些子集构建独立的 LDA 模型,由此提取每一阶段的关键主题,在 LDA 模型的训练阶段,我们利用吉布斯采样方法实施参数估计,获得每个话题在文本集合里的分布概率,同时获得每个话题下关键词的概率分布数据,利用这些分布信息,我们可以识别得出在变点前后,文本语义结构是否出现明显变动,哪些话题新崭露头角,哪些话题退出视野,以及话题强度是否出现明显的变动。

4 实验与分析

4.1 多源数据采集与清洗

4.1.1 数据采集

本研究借助数据驱动的研究途径,数据取自权威汽车行业的投诉与召回信息平台,皆为中国市场监管体系之内具有公信力的第三方平台,为保证研究的时效性与代

表性，我们专门选择了和2024 年汽车品牌全球销量前 20 密切相关的数据进行详细分析。按照易车榜平台统计报告，日本的丰田、德国的大众、美国的福特三个品牌占据了全球销量前三名，各品牌销量分别到了 844 万、502 万和 375 万，中国品牌比亚迪随后就跟上，销量为 373 万辆，本研究的数据采集是围绕着这些销量领先的汽车品牌开展的。

- 汽车投诉中国网³：采集 2019 年 1 月 16 日至 2024 年 10 月 1 日期间发布的消费者投诉数据，覆盖车型、品牌、故障类型、投诉时间等关键字段，重点聚焦于 TOP20 销量品牌的投诉记录，共计 45,783 条。
- 中国汽车质量网⁴：提取 2024 年 7 月 3 日至 2024 年 9 月 19 日期间的投诉数据，同样专注于 TOP20 销量品牌的质量缺陷描述与投诉内容，共计 6,093 条。
- 汽车召回网⁵：汇总 2019 年 1 月至 2024 年 10 月期间国家市场监督管理总局发布的全部召回公告，重点分析 TOP20 销量品牌的召回批次、缺陷原因及修复措施等信息，共计 9,855 条。

研究样本覆盖了日系、德系、美系、中系、韩系、法系以及意大利等不同国家和地区的汽车品牌，有丰田、大众、福特、比亚迪、本田、铃木、日产、马自达、奔驰、宝马、奥迪、雪佛兰、特斯拉、吉利汽车、五菱汽车、现代、起亚、雷诺、标致和菲亚特等。这些品牌不仅在全球整体销量上名列前茅，而且在中国市场还具备较高的知名度及影响力，接下来将开展数据清洗事宜，之后开展数据质量检验，从而保证研究的准确与可靠。

在数据处理过程中，选取了投诉时间、投诉品牌、投诉车系、投诉车型、投诉内容等 23 个字段。这些字段的选择紧密围绕后续的研究目标，旨在为变点检测、对比分析等研究工作提供有力的数据支持。在对比分析中，可借助这些字段对投诉且召回、有投诉无召回、有召回无投诉这三种情况进行分类统计，深入挖掘汽车质量问题与召回之间的内在关系。

³<https://315.auto.china.com.cn/zlts/complaint-list.html>

⁴<https://www.aqsiqauto.com/>

⁵<https://qiche365.org.cn/>

表 1: 2024 年汽车品牌全球销量 TOP20

品牌	国家	全球销量 (万辆)
丰田 (Toyota)	日本	844.77
大众 (Volkswagen)	德国	502.37
福特 (Ford)	美国	375.49
比亚迪 (BYD)	中国	373.43
本田 (Honda)	日本	358.94
现代 (Hyundai)	韩国	345.65
铃木 (Suzuki)	日本	308.50
日产 (Nissan)	日本	299.10
起亚 (Kia)	韩国	266.27
雪佛兰 (Chevrolet)	美国	257.95
奔驰 (Mercedes-Benz)	德国	217.29
宝马 (BMW)	德国	209.16
特斯拉 (Tesla)	美国	172.05
奥迪 (Audi)	德国	163.77
雷诺 (Renault)	法国	145.36
马自达 (Mazda)	日本	121.15
吉利汽车 (Geely)	中国	115.31
菲亚特 (Fiat)	意大利	114.21
标致 (Peugeot)	法国	104.82
五菱汽车 (Wuling)	中国	96.93

就时间变点分析而言，作为关键的时间序列数据的“投诉时间”，为基于 LDA - MLC 模型的变点检测搭建了重要的时间维度基础，结合“投诉内容”等别的相关字段，能对不同时间粒度范畴内的文本语义变化进行分析，进而察觉投诉文本中潜在的变点，依靠对这些变点的研究工作，可以表明汽车质量问题在时间轴里的动态变化趋势，为汽车制造商提前找出质量隐患、提升产品质量提供科学凭据，协助汽车行业提升整体产品品质和服务水平。

本研究运用 Python 编写的网络爬虫程序，依靠 Requests 和 BeautifulSoup 这两个库，依靠模拟浏览器请求系统，采集汽车投诉中国网和中国汽车质量网的投诉详情页数据，程序自行对 HTML 中的投诉编号、品牌车型、问题描述、处理流程等 21 个结构化字段做解析，一并把关联的图片及视频文件进行归档，最终把内容以 CSV 格式存储且记录多媒体文件数量，采集期间依靠异常处理机制维持数据的完整性。

4.1.2 数据清洗与预处理

依靠原始数据集中的 23 个字段，我们结合研究目标进行关键字段的提取，最终选出来的字段有投诉时间、投诉品牌、投诉车系、投诉车型以及投诉内容，对这些字段的筛选聚焦车辆质量问题的时空分布特征情况，保留结构化元数据跟非结构化文本的对应关系，剔除跟研究问题关联紧密程度低的辅助性字段，为后续开展文本分析与特征工程提供基础数据框架。

表 2: 数据预处理字段提取说明

字段名称	数据类型	描述	示例数据
投诉时间	时间戳	消费者提交投诉的具体日期与时间	2022-01-01 03:36:5
投诉品牌	分类变量	车辆制造商名称	福克斯
投诉车系	分类变量	车辆产品系列名称	Focus
投诉车型	分类变量	车辆具体型号	2016版Focus2.0
投诉内容	文本	消费者描述的质量问题详情	避震漏油一年一换

文本标准化：为利于后续分析工作，采用腾讯云机器翻译 API 对原始的中文投诉内容进行标准化操作，把文本大规模转换为英文，采用 Python SDK 调用翻译服务，同时添加精准的延时控制办法，严格把请求频率控制在 5.26 次/秒的安全阈值界限内，把每条请求的间隔控制成 0.19 秒。处理期间自动跳过空值数据，翻译未成功的记录保留原文，同时记录错误日志，最终拿出包含标准化英文文本的结构化数据集，随后从翻译好的结构化数据里随机抽取 1% 作为样本，对抽取的样本开展人工检查，保证词汇翻译精准、句子结构完整以及语义一致。把全部字符转换为小写接着分词，同时去除标点符号（像” /”、” @”、” |”）、数字、停用词（像” the”、” a”、” and”）以及 URL 链接，采用 WordNet 词形还原器让词语呈现基本形式，以此降低词汇冗余度，依照自然语言处理的通行做法，设定稀疏度为 0.99 来过滤文档里不常出现的词汇，最终保留至少在 1% 文档里有出现的高频词汇组成分析词库。

车型对齐：通过基于预训练语言模型的语义匹配方法，去解决不同数据源里车型描述不一致的问题，首先对投诉数据跟召回数据中的品牌、车系、车型字段做文本清洗工作，而后把各字段拼接成完整的表述文本，接着借助 Sentence - BERT 模型算出投诉文本与召回文本的语义嵌入向量，并利用余弦相似度开展匹配任务，就成功完成匹配的记录，把匹配成功的记录统一映射成标准车型说法，最终造就包含统一字段的标准数据集，为后续分析保障了数据的一致性。




图 2: 数据处理流程图

为了进行车型数据的标准化处理，我们首先进行字段拼接操作，其中投诉数据集 $D_{\text{complaint}}$ 通过将品牌名称 b_i 、车系名称 s_i 和车型名称 m_i 进行拼接得到。同样地，召回数据集 (D_{recall}) 通过将厂商前缀 (mf_j)、车系名称 (s_j)、年款 (y_j) 和配置 (t_j) 进行拼接来表示：

$$D_{\text{complaint}} = \bigcup_{i=1}^n (b_i \parallel s_i \parallel m_i) \quad (17)$$

$$D_{\text{recall}} = \bigcup_{j=1}^m (mf_j \parallel s_j \parallel y_j \parallel t_j) \quad (18)$$

表 3: 车型描述不一致举例

匹配的问题	未清洗数据示例
品牌名称简写与全称差异	大众探岳 2015 基础款 QS 版 一汽大众探岳 SQ 2015 版（基础配置）
车系名称顺序差异	Buick LeSabre 2020 LeSabre Buick 2020
年款位置歧义	2021 款 BMW X3 xDrive30i BMW X3 2021 xDrive30i
配置描述术语差异	Honda Accord EX-L with Navigation Accord EX-L Navigation Package
厂商前缀差异	华晨宝马 320Li 宝马 320Li 2022 款

接下来，我们通过语义嵌入计算来捕捉文本信息的语义特征。假设输入为一个词向量序列 $(x = [w_1, w_2, \dots, w_n])$ ，我们首先通过嵌入层将其映射到低维空间，得到嵌入矩阵 E 。然后，经过多头自注意力（MultiHeadAttn）层处理，得到隐藏表示 $\mathbf{H}^L$ 。最后，我们通过池化操作计算出每个词的平均向量 $\mathbf{h}$ ，表示句子的语义特征。为了计算文本之间的相似度，我们使用余弦相似度度量文本的语义相似性。对于两个文本向量 $\mathbf{h}_c$ 和 $\mathbf{h}_r$ ，其余弦相似度的计算公式为：

$$\text{Sim}(\mathbf{h}_c, \mathbf{h}_r) = \frac{\mathbf{h}_c \cdot \mathbf{h}_r}{\|\mathbf{h}_c\| \cdot \|\mathbf{h}_r\|} = \frac{\sum_{k=1}^d h_c^{(k)} h_r^{(k)}}{\sqrt{\sum_{k=1}^d (h_c^{(k)})^2} \sqrt{\sum_{k=1}^d (h_r^{(k)})^2}} \quad (19)$$

最后，通过一个映射决策函数 $f(x)$ ，我们根据余弦相似度的结果决定字段是否匹配。如果存在一个标准名称 std_name_j 使得 $\text{Sim}(\mathbf{h}_x, \mathbf{h}_j) \geq \tau$ ，则返回该标准名称；否则，返回 “Unmatched”：

$$f(x) = \begin{cases} \text{std_name}_j, & \text{if } \exists j \text{ s.t. } \text{Sim}(\mathbf{h}_x, \mathbf{h}_j) \geq \tau \\ \text{Unmatched}, & \text{otherwise} \end{cases} \quad \text{where } \tau = 0.7$$

通过以上方法，我们能够将不一致的车型描述进行有效的匹配和标准化处理。

表 4: 模型性能评估结果

指标	总数	成功匹配条数	数据清洗率
投诉数据	51876	44470	85.72%
召回数据	9855	2040	20.7%

表 5: 投诉评论文本数据量前十车型分布

车型（统一字段）	计数	占比
比亚迪汽车全新一代唐 2021 2021 款唐 DM-i 尊贵型	1,903	4.3%
广汽丰田赛那	1,757	4.0%
北京汽车	1,364	3.1%
一汽大众探岳 X 2020 探岳 X 330TSI 旗舰智联版	1,364	3.1%
长安福特福睿斯 2019 新福睿斯 1.5L 自动悦享型	1,318	3.0%
长安福特锐际 2021 锐际插电混动版	1,198	2.7%
奔驰汽车 E 级	1,179	2.7%
上海雅升斯宾特商务车	885	2.0%
天津一汽丰田奕泽无奕驰版	874	2.0%
长安福特蒙迪欧致胜 2013 致胜 2.3L 豪华型	866	1.9%

4.2 市场代表性

为评估研究样本在品牌类别上的行业代表性,本文采用 Kolmogorov–Smirnov(K–S) 检验方法,对样本分布与 2024 年市场总体分布进行一致性分析。K–S 检验是一种基于累积分布函数(CDF)最大差异的非参数检验,适用于样本量较大的场景,能够有效评估两组分布之间是否存在统计学显著差异。检验的原假设和备择假设定义如下:

$$H_0 : F_n(x) = F_m(x), \quad \forall x; \quad H_1 : \exists x \text{ s.t. } F_n(x) \neq F_m(x). \quad (20)$$

首先,按照品牌属性划分,自主品牌、合资品牌与豪华品牌在样本与市场中的比例如表6所示。

表 6: 样本与市场品牌类别分布及累积分布

品牌类别	样本比例 (%)	样本 CDF (%)	市场比例 (%)	市场 CDF (%)
自主品牌	34.9	34.9	65.2	65.2
合资品牌	49.5	84.4	27.8	93.0
豪华品牌	15.0	99.4	7.0	100.0

基于表6数据, 计算样本与市场累积分布函数 $F_n(x)$ 和 $F_m(x)$ 之间的最大差异:

$$D_{n,m} = \sup_x |F_n(x) - F_m(x)|. \quad (21)$$

即:

$$D_{n,m} = \max\{|34.9\% - 65.2\%|, |84.4\% - 93.0\%|, |99.4\% - 100.0\%|\} \quad (22)$$

$$= 30.3\% = 0.303. \quad (23)$$

根据 K-S 检验的临界值公式, 当显著性水平 $\alpha = 0.05$ 时,

$$D_\alpha = c(\alpha) \sqrt{\frac{n+m}{nm}}, \quad c(0.05) = 1.36. \quad (24)$$

在样本量较大的情况下, 比较可得 $D_{n,m} < D_\alpha$, 或等价地, 推算 $p = 0.21 > 0.05$, 因此不拒绝原假设 H_0 。K-S 检验结果表明, 本研究样本与 2024 年市场总体品牌结构分布不存在统计学显著差异 ($D_{n,m} = 0.303, p = 0.21$), 研究样本具有良好的行业代表性。

4.3 案例分析: 比亚迪汽车全新一代唐 2021 款唐 DM-i 尊贵型

为深入了解汽车投诉文本里的主题漂移现象, 依照表5当中的结果, 本研究选取单车型表当中投诉数据最多的车型——比亚迪全新一代唐 2021 款唐 DM-i 尊贵型进行实验。

该车型投诉数据的时间跨度是从 2021 年 5 月起至 2024 年 10 月, 囊括了丰富的用户投诉相关评论, 顾及到时间序列的特征以及数据的完整性, 本研究以月份作为时间粒度对数据做划分, 从 2021 年 5 月起至 2024 年 10 月, 合计被划成 42 个阶段, 这种划分途径可精细把握每月投诉内容的变化, 又能保障数据量充沛。

通过改进的 LDA-MLC 模型对投诉文本进行动态主题建模与变点检测。经过多次迭代训练，模型收敛至稳定状态，最终筛查出 11 个显著变点，将序列区分为 12 个主题演化阶段，变点位置跟中国国家市场监督管理总局发布的召回公告时间（2022 年 7 月）⁶高度重合，初步核实模型提前两个月发出预警的能力。




图 3: 模型变点检测结果

基于 LDA-MLC 模型检测出的 12 个阶段，我们对每个阶段的投诉数据分别进行了 LDA 主题建模分析。

表 7: 比亚迪汽车投诉主题流行度演化分析

阶段	时间范围	主题名称	关键词	流行度 (%)
1	2021/05 -2021/06	预售纠纷	比亚迪, 客户, 预售, 官方, 门店, 保修, 订单, 购前, 销售, 周期	40
		维护延迟	门店, 制造商, 回复, 零件, 到期, 维护, 权益, 问题, 比亚迪	20
		拒绝履约	销售人员, 门店, 然而, 致电, 认为, 新款, 支付, 拒绝, 元	20
		定金争议	定金, 订单, 保修, 权益, 享受, 承诺, 免费, 预售, 问题, 比亚迪	20
2	2021/07 -2021/12	提车延误	月份, 门店, 销售, 提车, 时间, 交付, 运送, 定金, 合同, 比亚迪	36
		合同问题	门店, 订单, 制造商, 月份, 时间, 致电, 合同, 结束, 销售, 天数	13.33
		到货等待	销售, 月份, 门店, 提车, 等待, 到达, 预订, 时间, 合同	12
		交付延迟	时间, 店铺, 交付, 天数, 月份, 遥远, 公司, 已付款, 立即, 总是	9.33
		回复慢	月份, 门店, 制造商, 时间, 等待, 定金, 给予, 喜欢, 回复, 已交付	6.67

续下页

⁶https://www.samr.gov.cn/cms_files/filemanager/samr/www/samrnew/zw/zh/202207/t20220729_349022.html

阶段	时间范围	主题名称	关键词	流 行 度 (%)
3	2022/01 -2022/07	交付流程	月份, 时间, 销售, 订单, 交付, 提车, 制造商, 定金, 运送, 门店	31.21
		服务不佳	门店, 问题, 天数, 服务, 制造商, 时间, 询问, 客户, 新款, 店铺	15.61
		补贴问题	补贴, 销售, 天数, 制造商, 月份, 动力, 时间, 已订购, 型号	12.14
		电池故障	门店, 电池, 问题, 时间, 新款, 电池组, 制造商, 能耗, 燃油	8.67
		优先交付	门店, 产线, 交付, 年份, 宋, 型号, 生产线, 能源, 制造商, 优先级	7.51
4	2022/08 -2022/09	产能不足	时间, 月份, 已交付, 制造商, 销售, 无法, 承诺, 生产, 经销商, 合同	20.24
		系统问题	时间, 服务, 系统, 天数, 权益, 问题, 销售, 门店, PDI	13.1
		异常里程	电池, 前部, 公里数, 门店, 问题, 电话, 显示, 续航	31.9
		测试问题	电池, 问题, 门店, 客户, 动力, 制造商, 天数, 测试, 充电	19.71
		赠品纠纷	提车, 月份, 时间, 赠品, 门店, 销售, 礼包, 补贴, 制造商	9.52
5	2022/10 -2023/02	退款难题	月份, 定金, 元, 天数, 时间, 销售, 退款, 合同, 销售人员, 承诺	17.39
		油液泄漏	问题, 公里数, 驾驶, 店铺, 泄漏, 月份, 时间, 机油, 电池, 发生	15.22
		动力故障	动力, 驾驶, 电池, 时间, 问题, 发动机, 门店, 速度, 制造商, 服务	15.22
		售后拖延	门店, 时间, 天数, 问题, 回复, 售后, 需要, 服务, 后来, 询问	14.13
		启动失败	动力, 电池, 店铺, 启动, 丢失, 门店, 维护, 失败, 天数, 分钟	8.7
6	2023/03 -2023/05	悬挂争议	车主, 旧款, 悬挂, 价格, 型号, 新款, NFC, 苹果, FSD, 元	18.31
		刹车问题	问题, 故障, 门店, 驾驶, 质量, 服务, 刹车, 售后, 发生	16.9
		优惠缺失	价格, 门店, 时间, 限时, 驾驶, 未提供, 折扣, 削减, 同样	15.49
		利率争议	价格, 门店, 消费者, 型号, 销售, 比亚迪, 购买, 根据, 月份, 利息	14.08
		驾驶体验差	门店, 问题, 驾驶, 天数, 时间, 消费者, 同样, 询问, 店铺, 销售	11.27
7	2023/06 -2023/08	自动启停	发动机, 模式, 已启动, 燃油, 机油, 车主, 驾驶, 自动, 时间	14.04
		排放争议	车主, 发动机, 燃油, 油箱, 排放, OTA, 行业, 偷偷, 技术, 忽视	10.88
		维护不透明	发动机, 车主, 模式, 启动中, 消费者, 电动, 燃油, 维护, 油箱	7.94
		首保问题	问题, 门店, 时间, 质量, 服务, 客户, 车门, 月份, 权益, 首次	7.6
		电池失效	电池, 门店, 时间, 动力, 问题, 驾驶, 店铺, 天数, 故障, 异常	7.43
8	2023/09 -2024/01	驱动故障	发动机, 车主, 模式, 启动, 燃油, 油箱, 偷偷, 维护, 纯电, 增加	13.46
		噪音问题	问题, 时间, 异常, 雨刷, 店铺, 前部, 维修, 门店, 权益, 噪音	15.73
		收费不清	服务, 费用, 价格, 门店, 收费, 金融, 销售, 时间, 消费者, 车主	13.48
		轮胎刹车	店铺, 天数, 问题, 轮胎, 刹车, 速度, 疑问, 购买, 制造商, 质量	12.36
		测试不准	门店, 问题, 时间, 售后, 天数, 驾驶, 服务, 轮胎, 测试	8.43
9	2024/02 -2024/03	降配争议	价格, 减配, 型号, 年份, 车主, 月份, 新款, 补偿, 版本	13.26
		降价投诉	元, 价格, 月份, 购买, 降价, 新款, 版本, 年份, 已购, 宋	15.75
		企业责任	车主, 旧款, 价格, 公司, 权益, 利息, 提供, 消费者, 要求, 希望	12.89
		信任危机	价格, 元, 降价, 购买, 月份, 年份, 新款, 降价, 时间, 削减	12.41
		动力故障	时间, 动力, 问题, 售后, 门店, 服务, 发动机, 多次, 驾驶, 店铺	6.92
10	2024/04 -2024/05	补偿诉求	价格, 车主, 降价, 旧款, 时间, 降价, 补偿, 月份, 购买	18.21
		噪音油耗	发动机, 时间, 问题, 门店, 启动, 噪音, 年份, 燃油, 严重, 驾驶	12.82
		销售违规	发动机, 车主, 燃油, 油箱, 模式, 纯电, 销售, 电动, 驾驶	11.11
		空调轮胎	时间, 店铺, 空调, 轮胎, 门店, 公里数, 速度, 车轮, 功能, 制冷	11.11
		维修问题	门店, 天数, 发动机, 机油, 店铺, 原因, 问题, 动力, 仍然, 维护	9.4
11	2024/06 -2024/07	电池问题	问题, 门店, 驾驶, 时间, 发生, 店铺, 新款, 动力, 质量	12.63
		启动失败	发动机, 启动, 时间, 强制, 元, 天数, 机油, 制造商, 损失, 消费者	12.7

续下页

阶段	时间范围	主题名称	关键词	流行度 (%)
		启动问题	发动机, 启动, 模式, 问题, 年份, 时间, 公里数, 动力, 电池, 驾驶	11.11
		升级失败	问题, 电池, 维护, 动力, 时间, 门店, 店铺, 升级	10.32
		退货请求	价格, 消费者, 时间, 型号, 销售, 元, 发动机, 月份, 利息, 退货	10.32
12	2024/08	异响返修	问题, 门店, 异常, 时间, 更换, 声音, 噪音, 发生, 维修, 新款	12.81
	-2024/10	屏幕轮胎	门店, 轮胎, 问题, 店铺, 维护, 时间, 屏幕, 服务, 驾驶	12.72
		生锈投诉	问题, 车门, 门店, 质量, 生锈, 异常, 新款, 时间, 更换, 锈蚀	12.72
		自动故障	时间, 发动机, 问题, 维修, 已启动, 自动, 天数, 动力, 制造商	11.84
		系统异常	门店, 驾驶, 价格, 发动机, 店铺, 维护, 系统, 告知	8.77

本实验凭借研究建立的时间序列主题模型与变点检测，揭示了比亚迪全新一代 2021 款唐 DM-i 尊贵型投诉文本中消费者关注焦点的转化规律。

从表7里阶段性主题的分布能看到，投诉热点展现出明显的时间动态属性：早期（阶段 1-2），交付环节集中爆发预售纠纷、提车延误等问题，好比“预售”“定金争议”等关键词流行度占到 40%，中期（阶段 4-7）渐渐转向产能不足、系统异常这类技术缺陷，其中“产能不足”主题流行度是 20.24 个百分点；在后期（阶段 9-12），投诉热点演变为降价争议、电池故障等质量与服务矛盾，像阶段 11，“电池问题”与“启动失败”主题一起突显。

这种主题漂移现象不但反映出产品整个生命周期的质量波动，更揭示出企业危机响应方面的滞后情况——模型检测到的 11 个显著变点中，只有 1 个与官方召回的相关公告直接关联，剩下 10 个非召回对应的变点均显示潜在质量风险未被及时察觉，这反映汽车企业需尽早辨认并发现投诉主题漂移的规律，尽早作出明智的召回判断。

深入分析主题的演化路径得出，高频投诉主题凸显出明显的“质量缺陷 - 服务响应 - 品牌信任”传导链迹象，阶段 5 的“油液泄漏”（15.22%）若未能有效处理，直接产生阶段 7 的“维护不透明”，最终会导致阶段 9 的“信任危机”（12.41%）现象。

这种舆情扩散机制传达出，企业要搭建基于主题流行度与变点密度的风险预警矩阵：对流行度变动超过 15% 的主题开启应急响应，对变点连续出现的时段强化舆情监控，结合图3反映的变点分布规律，建议厂商构筑“三阶干预模型”：售前阶段把精力放在交付流程优化上，售中阶段强化技术缺陷的闭环管理，售后阶段做好客户信任修复工作，凭借动态主题跟踪来实现质量管理的 PDCA 循环。

企业要在销售环节强化合同管理、做好交付把控，生产环节要保障产能及质量水平，售后环节把质量问题反馈处理机制健全，依照召回资讯，比亚迪因部分车辆动力电池包托盘具备进水风险而实施召回，这说明了电池安全问题的重要意义。在出现的投诉主题里面，不同阶段里，电池故障、电池失效等主题均有出现，就像阶段 3 “电池故障” 主题的流行度为 8.67%，阶段 4 “异常里程” 主题流行度有 31.9%，按照比亚迪汽车召回事件印证，阶段 3 跟阶段 4 之间的变点和 2022 年 7 月召回公告相契合，召回前后所聚焦的问题主题变化显著，召回前交付、服务类主题格外突出，当召回结束，质量相关的主题明显增多，证实了召回在消费者关注焦点转移方面的影响。

汽车生产厂家要为电池等核心部件搭建长期质量跟踪档案，优化产品设计以及服务流程，切实利用起舆情监测与预警机制，就高频、关键问题编制预案，借此提高整体客户满意度及品牌形象，企业实施召回行动时，需充分重视其在客户情绪上引发的连锁反应，赶紧采取应对行动，提升信息披露水平、快速响应客户的诉求、依靠多渠道正面引导舆论，提议企业建立舆情监测及预警机制，实时盯紧投诉数据的结构改变态势，预先判别潜在的危机节点，进而达成“事前防控、事中响应、事后修复”的闭环管理模式。

5 结论

本研究按照多源缺陷信息驱动的思路开展，提出并达成了一种把改进 LDA-MLC 模型和 n -gram 文本特征、动态变点检测和预警机制结合起来的汽车召回预警框架，把国内外权威投诉与召回公告数据进行了整合，借助 Sentence-BERT 与余弦相似度达成车型标准化映射，保障了输入数据的一致性与高水准。依靠 DP-HMM 改进的 LDA-MLC 模型以及 n -gram 拓展，有效抓取了投诉文本中潜在的主题漂移和语义方面的变化，做到了对主题浓度变化的细腻勾勒；借助 Kolmogorov-Smirnov 检验验证了样本品牌分布在行业中的代表性，为后续的实证分析筑牢了坚实基础。

在案例分析这个过程里，选取比亚迪唐 DM-i 尊贵型为代表，设立了 42 个月度阶段的动态主题序列，识别出 11 个明显变点，其中和 2022 年 7 月召回公告前后语义变点有着高度重合，表明了模型可提前两个月发出预警的实力，通过对 12 个主题演化阶段开展 LDA 分析，发现了“质量缺陷-服务响应-品牌信任”三阶段舆情传导链，为企业构造基于主题流行度与变点密度的“三阶干预”舆情矩阵提供可操作策略。

本研究从理论层面丰富了多源异构数据驱动的动态主题建模与变点预警方面的研究,从实践情况看,为汽车制造商和监管机构提供了“事前防控 - 事中响应 - 事后修复”的闭环决策的相关支撑。

未来改进方向聚焦三个维度:在技术层面会进一步深化多模态数据融合,探索把车辆运行数据(像车载传感器数据)和文本数据相结合的混合建模办法;应用层面将拓宽预警系统的部署场景,开发面向 C 端消费群体的购车风险预警小程序;政策层面将携手行业协会构建召回预警数据共享平台,推动建立政府 - 企业 - 用户协同治理的新生态模式,通过不断革新模型算法、扩大数据接入层面、完善人机协同架构,本研究成果有潜力推动汽车召回管理从被动应对朝主动预防转型,为搭建更安全的汽车消费环境提供技术后盾。

参考文献

- [1] RHEE M, HAUNSCHILD P R. The Liability of Good Reputation: A Study of Product Recalls in the U.S. Automobile Industry[J]. Organization Science, 2006 [2025-04-06].
- [2] HORA M, BAPUJI H, ROTH A V. Safety hazard and time to recall: The role of recall strategy, product defect type, and supply chain player in the U.S. toy industry[J/OL]. Journal of Operations Management, 2011, 29(7): 766-777.
- [3] SHI W, LENG K, VAN NIEUWENHUYSE I, et al. Vehicle recalls performance in an emerging market: Evidence from the comparison between China and U.S. [J/OL]. Transportation Research Part A: Policy and Practice, 2020, 132: 290-307.
- [4] 吴剑琳, 古继宝, 代祺. 产品伤害危机对购买意愿的影响: 消费者人口统计特征的调节作用——以丰田召回事件为例[J]. 软科学, 2012, 26(2): 25-29.
- [5] CHEN Y, GANESAN S, LIU Y. Does a Firm's Product - Recall Strategy Affect Its Financial Value? An Examination of Strategic Alternatives during Product - Harm Crises.[J]. Journal of Marketing, 2009, 73(6): 214-226. JSTOR: 20619070.
- [6] THOMSEN M R, MCKENZIE A M. Market Incentives for Safe Foods: An Examination of Shareholder Losses from Meat and Poultry Recalls[J]. American Journal of Agricultural Economics, 2001, 83(3): 526-538 [2025-04-13].

- [7] RUPP N G. Are Government Initiated Recalls More Damaging for Shareholders? Evidence from Automotive Recalls, 1973–1998[J]. *Economics Letters*, 2001, 71(2): 265-270 [2025-04-13].
- [8] GOVINDARAJ S, JAGGI B, LIN B. Market Overreaction to Product Recall Revisited—the Case of Firestone Tires and the Ford Explorer[J]. *Review of Quantitative Finance and Accounting*, 2004, 23(1): 31-54 [2025-04-13].
- [9] ZHAO X, LI Y, FLYNN B B. The financial impact of product recall announcements in China[J/OL]. *International Journal of Production Economics*, 2013, 142(1): 115-123.
- [10] BEAMISH P W, BAPUJI H. Toy Recalls and China: Emotion vs. Evidence [J/OL]. *Management and Organization Review*, 2008, 4(2): 197-209.
- [11] HAUNSCHILD P R, RHEE M. The Role of Volition in Organizational Learning: The Case of Automotive Product Recalls[J/OL]. *Management Science*, 2004, 50(11): 1545-1560.
- [12] 孙莹, 杜建刚, 李文忠, 等. 产品召回中的负面情绪和感知风险对消费者购买意愿的影响——基于汽车产品召回的实证研究[J]. *管理评论*, 2014, 26(2): 104-110.
- [13] KALAI GNANAM K, KUSHWAHA T, EILERT M. The Impact of Product Recalls on Future Product Reliability and Future Accidents: Evidence from the Automobile Industry[J]. *Journal of Marketing*, 2013, 77(2): 41-57 [2025-04-13].
- [14] CHAO G H. Quality Improvement Incentives and Product Recall Cost Sharing Contracts[J].
- [15] Optimal Decision Rules for Product Recalls[J]. [2025-04-13].
- [16] BATES H, HOLWEG M, LEWIS M, et al. Motor vehicle recalls: Trends, patterns and emerging issues[J/OL]. *Omega*, 2007, 35(2): 202-210.
- [17] BARBER B M, DARROUGH M N. Product Reliability and Firm Value: The Experience of American and Japanese Automakers, 1973-1992[J/OL]. *Journal of Political Economy*, 1996, 104(5): 1084-1099.
- [18] 张光明. 缺陷产品召回管理预警体系研究[D]. 青岛: 青岛大学, 2009.
- [19] 代磊. 企业缺陷产品召回敏捷管理研究[D]. 长春: 吉林大学, 2013.
- [20] 王珊. 我国缺陷汽车召回制度的不足及完善[D]. 上海: 华东政法大学, 2013.

- [21] ZHONG N, SCHWEIDEL D A. Capturing Changes in Social Media Content: A Multiple Latent Changepoint Topic Model[J/OL]. *Marketing Science*, 2020, 39(4): 827-846.
- [22] GAO Y, DUAN W, RUI H. Does Social Media Accelerate Product Recalls? Evidence from the Pharmaceutical Industry[J/OL]. *Information Systems Research*, 2022, 33(3): 954-977.
- [23] FOSSEN B L, SCHWEIDEL D A. Measuring the Impact of Product Placement with Brand-Related Social Media Conversations and Website Traffic[J/OL]. *Marketing Science*, 2019, 38(3): 481-499.
- [24] CHAMROUKHI F, SAMÉ A, GOVAERT G, et al. A regression model with a hidden logistic process for feature extraction from time series: arXiv:1312.7001 [EB/OL]. arXiv. (2013-12-25). arXiv: 1312.7001[stat].
- [25] CHIB S. Estimation and comparison of multiple change-point models[J/OL]. *Journal of Econometrics*, 1998, 86(2): 221-241.
- [26] WANG S, LIN Y, ZHU G. Online reviews and high-involvement product sales: evidence from offline sales in the chinese automobile industry[J/OL]. *Electronic Commerce Research and Applications*, 2023, 57: 101231 [2025-01-24].
- [27] ASTVANSH V, WANG Y Y, SHI W. The effects of the news media on a firm's voluntary product recalls[J/OL]. *Production and Operations Management*, 2022, 31(11): 4223-4244.
- [28] CHEN Y, DAI X, FU P, et al. A review of China's automotive industry policy: recent developments and future trends[J/OL]. *Journal of Traffic and Transportation Engineering (English Edition)*, 2024, 11(5): 867-895 [2025-01-24].
- [29] GROOTENDORST M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure[EB/OL]. arXiv. 2022 [2025-04-22].
- [30] CHIB S. Calculating posterior distributions and modal estimates in Markov mixture models[J/OL]. *Journal of Econometrics*, 1996, 75(1): 79-97.